Présentation notebook

June 17, 2024

1 ml-in-the-clouds

1.1 Data Exploration

1.2 Préparation de la donnée

- On utilise TfidfVectorizer pour transformer des textes en vecteurs numériques pondérés par TF-IDF
- Et MultinomialNB pour classer des données textuelles.

1.3 Pycaret

1.3.1 Grid Search

1.4 Results

```
[1]: ### Results

# <img src="img/confusion_matrix.png" alt="df_fusion" width="50%">

# <img src="img/classification_report.png" alt="df_fusion" width="46%">

# <img src="img/pipeline.png" alt="df_fusion" width="97%">

# ### Results

# <img src="img/confusion_matrix.png" alt="df_fusion" width="40%">

# <img src="img/classification_report.png" alt="df_fusion" width="37%">

# <img src="img/pipeline.png" alt="df_fusion" width="96%">
```

1.5 DataRobot

1.6 Conclusion

- Performances proches entre Pycaret et DataRobot
- Performance encourageante sur le fichier Train et décevante sur le fichier Test
- La fusion des deux datasets n'a pas été concluante
- Application, Docker fonctionnels
- model déployé sur AWS depuis DataRobot